

Otimização de modelos com algoritmo genético

Fase 2 - diagnóstico, explicabilidade e operação

O desafio é otimizar sem contaminar a avaliação

A Fase 2 parte dos modelos da Fase 1 e adiciona uma busca evolutiva por hiperparâmetros.

O conjunto de teste é separado antes da otimização. A seleção ocorre apenas por validação cruzada no treino.

A LLM explica a previsão, mas não altera a classe calculada pelo modelo.



O dataset é pequeno, controlado e desbalanceado

O projeto usa o arquivo data.csv da Fase 1. O alvo binário distingue casos benignos e malignos, com estratificação em todas as divisões.

569

exames no conjunto
completo


30

variáveis numéricas por
exame

69

casos no teste reservado

A avaliação preserva o teste em três etapas



No teste reservado, o baseline logístico liderou

Todas as versões são comparadas sobre os mesmos 69 casos. Valores em percentual.

Modelo	Versão	Acurácia	Precisão	Recall	F1	ROC AUC
Regressão Logística	Baseline	98.55	100	96.15	98.04	99.46
Regressão Logística	GA	97.1	96.15	96.15	96.15	99.82
Random Forest	Baseline	97.1	96.15	96.15	96.15	99.46
Random Forest	GA	95.65	92.59	96.15	94.34	99.55

Maior AUC não compensou a queda nas métricas de decisão.

O algoritmo genético prioriza recall sem ignorar o F1

Fitness

$$0,65 \times \text{recall} + 0,35 \times F1$$

Representação

Cada indivíduo codifica hiperparâmetros válidos do modelo.

Evolução


Torneio, crossover uniforme, mutação, elitismo e cache de avaliações.

Seleção


Três configurações exploram diferentes populações e taxas evolutivas.

A busca converge cedo, mas encontra soluções diferentes por modelo


Regressão Logística



Random Forest



O GA melhora a discriminação, mas não a decisão final



Recall estável

96,15% nas quatro versões avaliadas.

AUC discretamente maior

99,82% na Regressão Logística com GA.

Métricas de decisão menores

Acurácia e F1 caíram após a otimização.

O custo da otimização aparece nos falsos positivos

Matrizes de confusão no teste reservado

Logistic Regression — Baseline

Classe real	Benigno	43	0
	Maligno	1	25
Predição		Benigno	Maligno

Random Forest — Baseline

Classe real	Benigno	42	1
	Maligno	1	25
Predição		Benigno	Maligno

Logistic Regression — Otimizado (GA)

Classe real	Benigno	42	1
	Maligno	1	25
Predição		Benigno	Maligno

Random Forest — Otimizado (GA)

Classe real	Benigno	41	2
	Maligno	1	25
Predição		Benigno	Maligno

Leitura do teste

- Todos os modelos deixaram escapar 1 caso maligno.
- O baseline logístico não gerou falso positivo.
- O GA acrescentou 1 falso positivo na Regressão Logística e 1 no Random Forest.
- Por isso, o ganho de AUC não define sozinho o modelo recomendado.

A LLM traduz evidências; ela não participa da predição



Guardrail principal: a resposta da LLM é validada por schema e possui fallback offline claramente identificado.

A solução está pronta para operar e ser observada

Entrega técnica

- API FastAPI
- Health e readiness checks
- Métricas Prometheus
- Logs estruturados em JSON
- Docker e Kubernetes HPA

Cuidados de uso

- Não enviar dados identificáveis à LLM
- Carregar apenas artefatos confiáveis
- Manter revisão humana
- Validar externamente antes de qualquer uso clínico
- Tratar as métricas como evidência educacional

O método funciona; o baseline continua melhor

A busca genética funcionou e foi reproduzível. O resultado correto é manter a melhor opção observada no teste, sem forçar uma narrativa de ganho.

98,55%

acurácia do baseline logístico

+0,36 pp

ganho de AUC com GA na
Regressão Logística

96,15%

recall mantido em todas as
versões

Manter o baseline de Regressão Logística

O GA permanece como evidência de otimização bem implementada.
A decisão final continua orientada pelas métricas do teste reservado.
Projeto educacional - não substitui avaliação clínica.